

# **SISTEMAS INTELIGENTES**

**Lecture 02: Introducción al  
Aprendizaje Automático  
(Machine Learning)**

**Dr. Edwin Valencia Castillo**  
Departamento de Sistemas  
Facultad de Ingeniería  
Universidad Nacional de Cajamarca  
**2024**

## Introducción


En el mundo actual impulsado por los datos, el aprendizaje automático ha surgido como una tecnología transformadora que permite a las computadoras aprender de los datos y tomar decisiones inteligentes.

Este poderoso campo de la inteligencia artificial tiene aplicaciones en diversos ámbitos, desde la atención sanitaria y las finanzas hasta el marketing y los vehículos autónomos.

Para obtener una comprensión más profunda del aprendizaje automático, es esencial explorar sus componentes principales, algoritmos, tipos y el proceso subyacente.

A continuación, profundizaremos en el mundo del aprendizaje automático, cubriendo todo, desde conceptos fundamentales hasta algoritmos comunes, el proceso de aprendizaje.

## Conceptos clave




### Aprendizaje automático (Machine Learning)

- El aprendizaje automático es un subconjunto de la inteligencia artificial que se centra en el desarrollo de algoritmos y modelos que permiten a las computadoras aprender y mejorar su desempeño en una tarea específica a través de la experiencia, sin estar programadas explícitamente.
- En esencia, el aprendizaje automático aprovecha los datos para hacer predicciones o decisiones, lo que lo convierte en una herramienta invaluable para la toma de decisiones basada en datos.



Las tareas más efectivas son aquellas que pueden tomar decisiones con base en la experiencia de otras conocidas.



### Ejemplos

- Identificar códigos postales manuscritos a partir de dígitos aprendidos
- Detectar usos fraudulentos de tarjetas de crédito a partir de transacciones
- Identificar temas en un conjunto de artículos de blog

## Algoritmos de Machine Learning

Los algoritmos de aprendizaje automático son el corazón y el alma de este campo.

Son modelos y técnicas matemáticas que permiten a las computadoras aprender patrones y relaciones dentro de los datos.

A continuación, se muestran algunos algoritmos clave de aprendizaje automático:

## Comprensión de la clasificación de algoritmos de aprendizaje automático

✓ Los algoritmos de aprendizaje automático se clasifican en términos generales según dos criterios clave:

➤ **Por la forma del aprendizaje:**

- Esta clasificación depende de cómo el algoritmo aprende de los datos. Incluye:

**Aprendizaje supervisado:** en el aprendizaje supervisado, los datos de entrada están etiquetados y el algoritmo tiene como objetivo aprender un mapeo de las entradas a las salidas. Los algoritmos comunes en esta categoría incluyen: decision trees, Bayesian classification, logistic regression, support vector machines, and neural networks.

**Aprendizaje no supervisado:** el aprendizaje no supervisado se ocupa de datos sin etiquetar y busca descubrir patrones, relaciones o grupos inherentes dentro de los datos. Los algoritmos notables incluyen independent component analysis, K-Means clustering, and Apriori association rule learning.

**Aprendizaje semisupervisado:** el aprendizaje semisupervisado se sitúa entre el aprendizaje supervisado y el no supervisado e implica datos parcialmente etiquetados. Los algoritmos de esta categoría incluyen graph theory inference algorithms and Laplacian support vector machines.

**Aprendizaje por refuerzo:** el aprendizaje por refuerzo enfatiza el aprendizaje a través de la interacción con un entorno para maximizar las recompensas esperadas. A diferencia del aprendizaje supervisado, no depende de pares precisos de entrada/salida y se utiliza comúnmente en tareas que requieren planificación y toma de decisiones en línea.

## Comprensión de la clasificación de algoritmos de aprendizaje automático

### ➤ Por la forma de aprendizaje: Aplicaciones



## Comprensión de la clasificación de algoritmos de aprendizaje automático

### ➤ Por la función:

- Los algoritmos también se pueden clasificar según sus funciones principales, que incluyen:

**Algoritmos de regresión:** estos algoritmos predicen valores numéricos continuos. Algunos ejemplos son linear regression, logistic regression, multiple adaptive regression, and local scatter smoothing estimates.

**Algoritmos de aprendizaje basados en instancias:** algoritmos como k-nearest neighbors (kNN), learning vectorization (LVQ), self-organizing mapping (SOM), and local weighted learning (LWL) se basan en el aprendizaje basado en instancias para tareas de clasificación.

**Algoritmos de regularización:** técnicas como ridge regression, LASSO (Least Absolute Shrinkage and Selection Operator), elastic net, and minimum angle regression (LARS) introducen la regularización para mejorar la estabilidad del modelo.

**Algoritmos de árbol de decisión:** estos algoritmos, incluido classification and regression tree (CART), ID3, C4.5, C5.0, and CHAID, crean estructuras en forma de árbol para tomar decisiones.

**Algoritmos bayesianos:** los métodos bayesianos, como naive Bayes, Gaussian Bayes, and Bayesian belief networks, utilizan el razonamiento probabilístico para la clasificación.

**Algoritmos basados en kernel:** Support vector machines (SVM), radial basis function (RBF), and linear discriminate analysis (LDA) pertenecen a esta categoría, y utilizan funciones del kernel para transformar datos en un espacio de mayor dimensión para su clasificación.

## Comprensión de la clasificación de algoritmos de aprendizaje automático

### ➤ Por la función:

- Los algoritmos también se pueden clasificar según sus funciones principales, que incluyen:

**Algoritmos de agrupación (Clustering):** algoritmos como k-means, hierarchical clustering, and EM (Expectation-Maximization) se centran en agrupar puntos de datos en grupos según la similitud

**Aprendizaje de reglas de asociación:** esta categoría incluye algoritmos como Apriori y Eclat, que identifican patrones frecuentes en los datos, a menudo utilizados en el análisis de la cesta del mercado.

**Redes neuronales:** las redes neuronales abarcan varias arquitecturas, como feedforward, backpropagation, Hopfield networks, and radial basis function networks (RBFN).

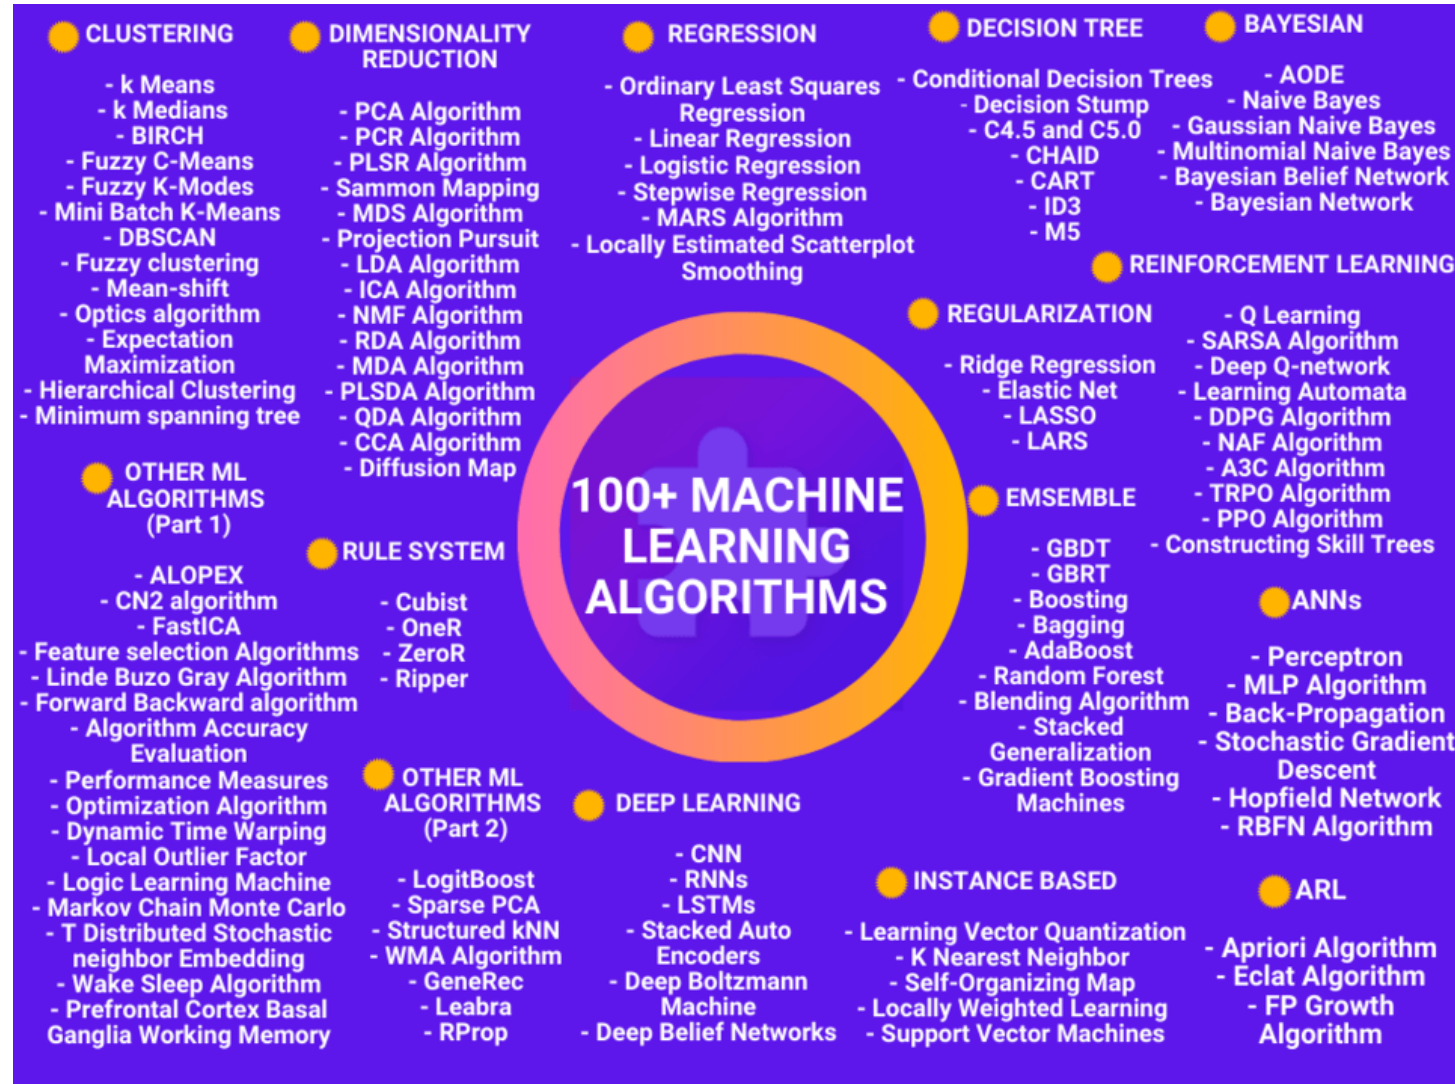
**Aprendizaje profundo:** los algoritmos de aprendizaje profundo involucran arquitecturas como deep Boltzmann machines (DBM), convolutional neural networks (CNN), recurrent neural networks (RNN), long short-term memory (LSTM), and stacked auto-encoders.

**Algoritmos de reducción de dimensionalidad:** técnicas como principal component analysis (PCA), partial least squares regression (PLSR), multidimensional scaling analysis (MDS), and linear discriminant analysis (LDA) tienen como objetivo reducir la dimensionalidad de los datos.

**Algoritmos integrados:** métodos como boosting, bagging, AdaBoost, and stack generalization combinan múltiples modelos para mejorar el rendimiento.

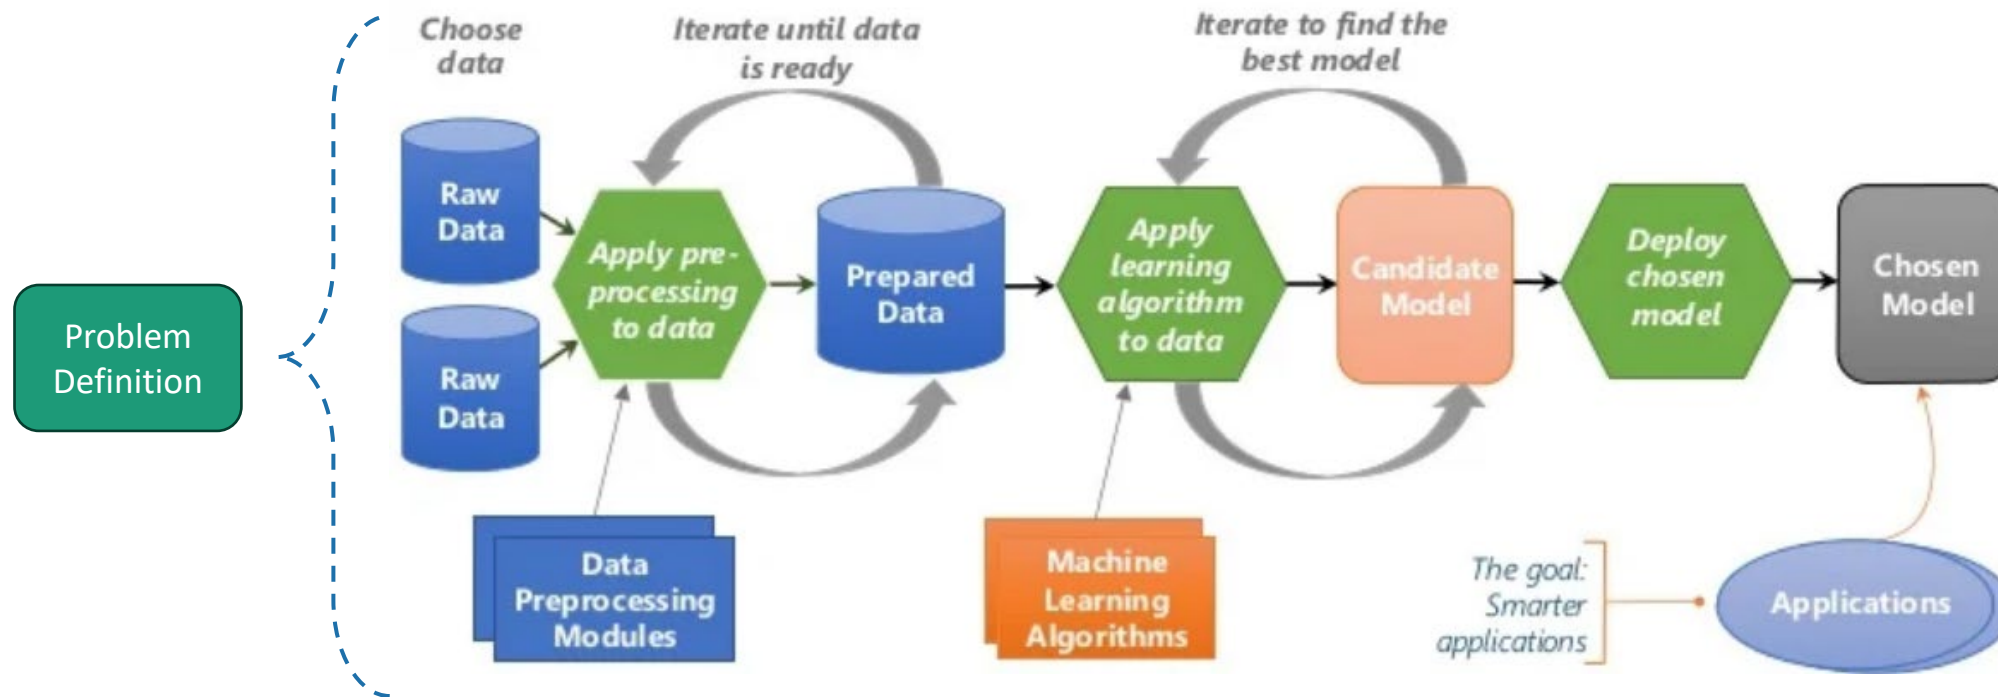


## Otros algoritmos de Machine Learning



## Machine Learning Process

- ✓ El proceso de Machine Learning es un enfoque sistemático para resolver problemas del mundo real utilizando técnicas de aprendizaje automático.
- ✓ Consta de varias etapas, cada una con sus tareas y desafíos específicos. Dividamos el proceso de aprendizaje automático en pasos clave:



## Machine Learning Process



## Profundizando conceptos sobre algoritmos de aprendizaje

- ✓ **Aprendizaje supervisado:** Utiliza ejemplos conocidos para obtener las inferencias. Predice un dato a partir de otros conocidos.
- ✓ **Aprendizaje no supervisado:** no dispone de ejemplos con un objetivo o etiqueta conocido. Se descubren patrones o tendencias en los datos.
- ✓ **Los problemas se pueden dividir en los siguientes 4 subtipos:**
  - **Aprendizaje supervisado:** problemas de regresión.
  - **Aprendizaje supervisado:** problemas de clasificación.
  - **Aprendizaje no supervisado:** problemas de agrupamiento.
  - **Aprendizaje no supervisado:** problemas de detección de anomalías

## Aprendizaje supervisado

- ✓ Consiste en entrenar un modelo usando un conjunto de datos etiquetados. A continuación, se presenta una explicación más formal:
- ✓ Definiciones Básicas
  1. Conjunto de Entrenamiento (Training Set): Es un conjunto de pares  $(x_i, y_i)$ , donde  $x_i$  representa las características (features) y  $y_i$  la etiqueta (label) correspondiente. Formalmente,  $D = \{(x_i, y_i)\}_{i=1}^N$ , donde  $N$  es el número de ejemplos en el conjunto de entrenamiento.
  2. Espacio de Características (Feature Space): Representado por  $X$ , es el dominio del cual provienen las características  $x_i$ . Puede ser un espacio de dimensiones  $\mathbb{R}^d$  si las características son numéricas.
  3. Espacio de Etiquetas (Label Space): Representado por  $Y$ , es el rango de las etiquetas  $y_i$ . En problemas de clasificación,  $Y$  es un conjunto finito de clases; en problemas de regresión,  $Y = \mathbb{R}$ .
- ✓ Objetivo del Aprendizaje Supervisado
  - El objetivo es encontrar una función de hipótesis  $h: X \rightarrow Y$  que mapee correctamente las características  $x_i$  a sus etiquetas  $y_i$ . Esta función  $h$  se denomina modelo.

## Aprendizaje supervisado: problemas de regresión

- ✓ En el aprendizaje supervisado tenemos datos que son generados por una «caja negra» donde un vector de variables de entrada  $x$  (llamadas variables independientes) entran por un lado y por otro lado las variables respuesta y son obtenidas.

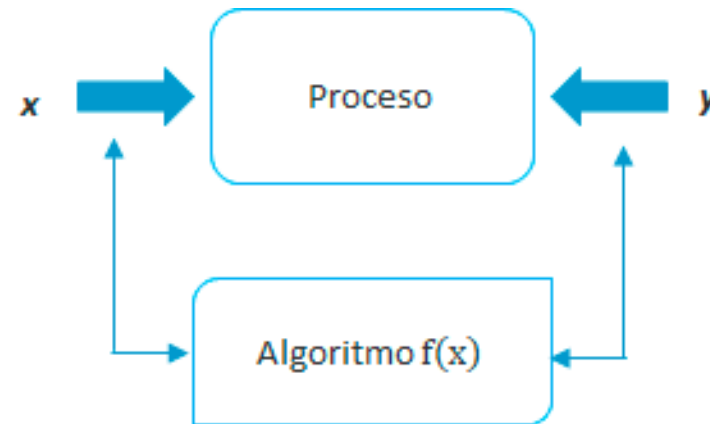


- ✓ En el caso concreto de los problemas de regresión la variable respuesta y del sistema que se desea inferir o generalizar es una variable cuantitativa (numérica continua).



## Aprendizaje supervisado: problemas de regresión

- ✓ Es decir, se considera el interior de la caja como algo complejo y desconocido. Por tanto, el enfoque es buscar una función  $f(x)$  que opere con los datos  $x$  para producir las respuestas  $y$ .



- ✓ La evaluación de este modelo se lleva a cabo por medio de la capacidad predictiva del modelo.

El aprendizaje supervisado tiene como objetivo generalizar las respuestas sobre datos no observados, utilizando para ello ejemplos observados previamente. En el caso de los problemas de regresión la variable respuesta  $y$  es una variable numérica continua.

## Aprendizaje supervisado: problemas de clasificación

En los problemas de clasificación, el aprendizaje supervisado utiliza ejemplos conocidos para inferir la etiqueta (clasificar) de los vectores de entrada  $x$  eligiendo una de entre varias categorías o clases.

Estos algoritmos, al igual que en los problemas de regresión, utilizan ejemplos etiquetados previamente para «aprender» los patrones para llevar a cabo una clasificación.

En este tipo de problemas la variable respuesta  $y$  es una variable con dos o más categorías.

En los problemas de clasificación, utilizando aprendizaje supervisado, el objetivo es identificar a qué categoría pertenece una nueva observación utilizando para ello una serie de observaciones y categorías conocidas previamente.



## Aprendizaje supervisado: problemas de clasificación

- ✓ Un ejemplo sería asignar a un correo electrónico la categoría de spam o no spam en función de los correos recibidos previamente. Otro ejemplo es realizar un diagnóstico a un paciente en función de sus características (sexo, presión sanguínea, colesterol, etc).
- ✓ Los problemas de clasificación se dividen en dos grandes grupos: clasificación binaria y clasificación multi-clase.
  - Los problemas de clasificación binaria buscan diferenciar las nuevas observaciones entre una de las dos clases posibles (ejemplo spam y no spam).
  - Los problemas de clasificación multi-clase conllevan asignar una nueva observación a una de entre varias clases posibles.


El aprendizaje supervisado tiene como objetivo generalizar utilizando para ello ejemplos conocidos. En el caso de los problemas de clasificación la variable respuesta y es una variable con 2 o más categorías o clases.

## Conceptos importantes de Machine Learning


✓ Para navegar eficazmente en el campo del Machine Learning, es fundamental comprender varios conceptos clave que sustentan los algoritmos y técnicas utilizados.




**Ingeniería de características (Feature Engineering):** la ingeniería de características implica seleccionar, transformar o crear características relevantes (variables de entrada) a partir de los datos sin procesar para mejorar el rendimiento de un modelo.




**Sobreajuste y subajuste (Overfitting and Underfitting):** el sobreajuste ocurre cuando un modelo aprende ruido en los datos de entrenamiento y tiene un rendimiento deficiente con datos nuevos. El subajuste ocurre cuando un modelo es demasiado simple para capturar los patrones subyacentes en los datos.



**Compensación sesgo-varianza (Bias-Variance Tradeoff):** La compensación sesgo-varianza es un concepto fundamental en la selección de modelos. Representa el equilibrio entre la capacidad de un modelo para ajustarse a los datos de entrenamiento (sesgo bajo) y su capacidad para generalizar a datos nuevos (varianza baja).



**Validación cruzada (Cross-Validation):** la validación cruzada es una técnica utilizada para evaluar el rendimiento de un modelo dividiendo los datos en múltiples subconjuntos y evaluando el modelo en diferentes combinaciones de conjuntos de entrenamiento y validación.



**Regularization:** las técnicas de regularización, como la regularización L1 y L2, se utilizan para evitar el sobreajuste agregando términos de penalización a la función de pérdida del modelo.

## Conceptos importantes de Machine Learning

### ✓ Conjuntos de entrenamiento, test y validación cruzada


- **Clave: Generalizar situaciones del futuro en función de los datos observados.**
- **Un modelo puede tener un error muy bajo en entrenamiento y no ser capaz de predecir bien los datos futuros.**
- **Una métrica más realista y objetiva es obtenida con un conjunto de test.**
- **Este procedimiento se conoce con el nombre de hold -out. Normalmente se utiliza un 80-20**
- **Ejemplo con el 80-20 ajustado para incluir validación**
  - Entrenamiento (Training Set): 64% (80% de 80%)
  - Validación (Validation Set): 16% (20% de 80%)
  - Prueba (Test Set): 20%

Estas proporciones aseguran que el modelo se entrene con la mayor cantidad de datos posible (80%), mientras que un subconjunto (20%) se reserva para evaluar el rendimiento final del modelo. Si necesitas un conjunto de validación, extraes un 20% adicional del conjunto de entrenamiento, resultando en 64% para entrenamiento y 16% para validación.

## Conceptos importantes de Machine Learning

### ✓ Validación Cruzada

- La repetición de la técnica de Hold-out es la base para la validación cruzada.
- Esta técnica también se conoce como K-Fold, donde K indica el número de conjuntos posibles.



## Técnicas de agrupamiento

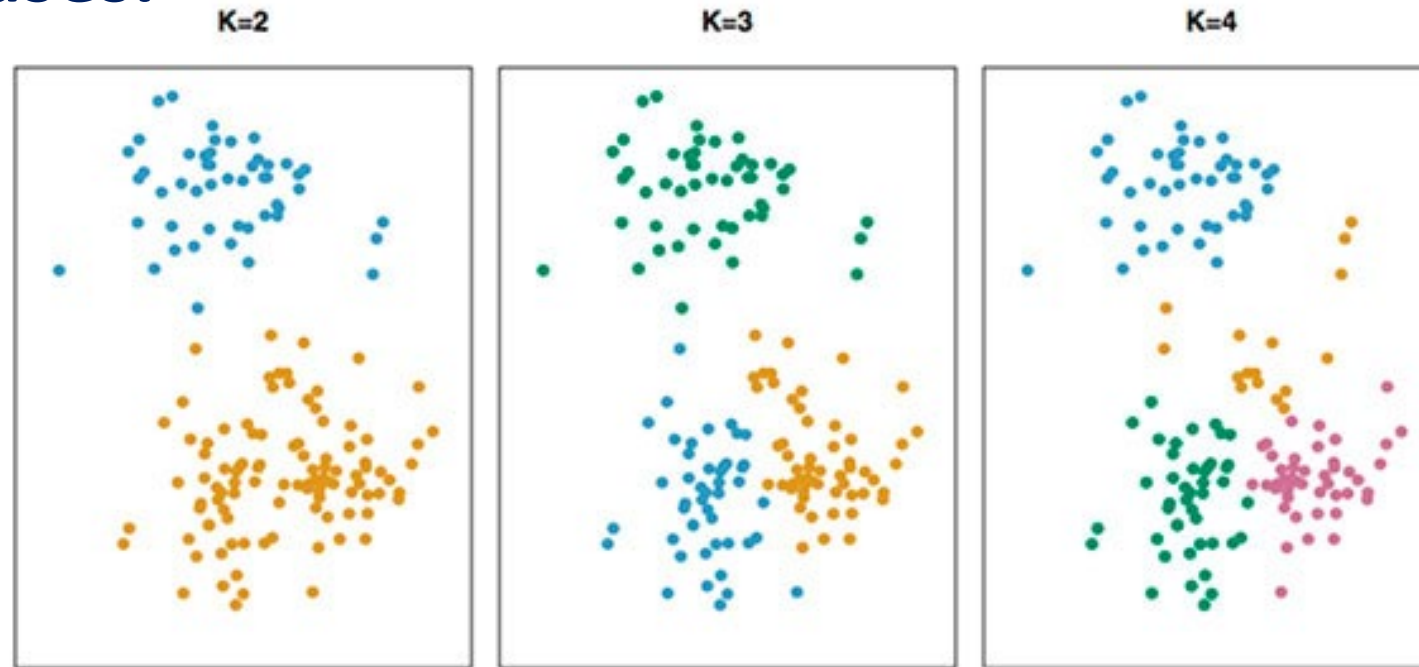
Las técnicas de agrupamiento o también conocidas como clustering son un ejemplo de aprendizaje no supervisado que se utilizan cuando desconocemos la etiqueta, clase o respuesta de las instancias de entrenamiento. En este tipo de problemas no se tiene conocimiento sobre las categorías o valores de los datos observados y se desea buscar la estructura oculta en los datos.

Por tanto, el proceso de modelado se lleva a cabo sobre un conjunto de ejemplos que solo contiene las entradas del sistema, y el algoritmo tiene que ser capaz de reconocer patrones para diferenciar entre los datos existentes. El resultado de estos algoritmos es una asignación de las observaciones a cada uno de los segmentos obtenidos.

La evaluación de este tipo de técnicas no es sencilla porque no se conoce el número de errores producidos. En concreto, cualquier método de evaluación sobre este tipo de técnicas no pueden calcularse con las etiquetas asignadas a las instancias sino con la separación que el algoritmo hace utilizando para ello métricas de similitud entre los miembros de cada una de las clases.

## Técnicas de agrupamiento

- ✓ En la siguiente figura se muestra la separación entre clases que llevaría a cabo un algoritmo de agrupamiento para dos, tres y cuatro clases.



Ejemplos de agrupamiento para tres diferentes valores de  $k$  sobre los mismos datos. Fuente: James et al, 2013

## Técnicas de detección de anomalías

- ✓ Una anomalía es una observación que es significativamente diferente del resto de observaciones. La detección de anomalías implica que esa observación es sospechosa de haber sido generada por un mecanismo diferente del resto de observaciones.
- ✓ La detección de anomalías es útil para dos objetivos diferentes. Por un lado, puede ser necesario eliminar estas anomalías de los datos para su posterior análisis. Por otro lado, el objetivo del análisis puede ser precisamente las anomalías y su origen.
- ✓ Los algoritmos de detección de anomalías también son conocidos con el nombre de detección de outliers. Estos problemas tienen gran aplicación en entornos como el fraude, la detección de intrusos, la detección de defectos estructurales, problemas médicos o errores en texto.



## Técnicas de detección de anomalías

- ✓ Los algoritmos de detección de anomalías se pueden clasificar entre:
  - Detección de anomalías supervisada.
  - Detección de anomalías no supervisada.
- ✓ La detección de anomalías de forma no supervisada busca anomalías en conjuntos de datos sin etiquetar con la hipótesis de que la mayoría de las instancias en el conjunto de datos son normales y observando aquellas que menos se parecen a la mayoría.
- ✓ Por otro lado, la detección de anomalías supervisada utiliza instancias o ejemplos previamente etiquetados como «normales» y «anormales» para entrenar un clasificador.



# PREGUNTAS??

**Dr. Edwin Valencia Castillo**  
Departamento de Sistemas  
Facultad de Ingeniería  
Universidad Nacional de Cajamarca  
**2024**